

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

MHA (Multi-Head Attention)

$$\mathbf{o}_t^{(s)} = \text{Attention} \left( \mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)} \right) \triangleq \frac{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right)} \quad (1)$$

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_q^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{k}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_k^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_k^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{v}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d \times d_v} \end{aligned}$$

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

MQA (Multi-Query Attention)

$$\mathbf{o}_t^{(s)} = \text{Attention} \left( \mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)} \right) \triangleq \frac{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right)} \quad (2)$$

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_q^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{k}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_k^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_k^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{v}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d \times d_v} \end{aligned}$$

事后看来，GQA的思想也很朴素，它就是将所有Head分为 $g$ 个组（ $g$ 可以整除 $h$ ），每组共享同一对K、V，用数学公式表示为

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

GQA  
(Group-Query Attention)

$$\mathbf{o}_t^{(s)} = \text{Attention} \left( \mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(\lceil sg/h \rceil)}, \mathbf{v}_{\leq t}^{(\lceil sg/h \rceil)} \right) \triangleq \frac{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(\lceil sg/h \rceil)\top} \right) \mathbf{v}_i^{(\lceil sg/h \rceil)}}{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(\lceil sg/h \rceil)\top} \right)} \quad (3)$$

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_q^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{k}_i^{(\lceil sg/h \rceil)} &= \mathbf{x}_i \mathbf{W}_k^{(\lceil sg/h \rceil)} \in \mathbb{R}^{d_k}, & \mathbf{W}_k^{(\lceil sg/h \rceil)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{v}_i^{(\lceil sg/h \rceil)} &= \mathbf{x}_i \mathbf{W}_v^{(\lceil sg/h \rceil)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(\lceil sg/h \rceil)} &\in \mathbb{R}^{d \times d_v} \end{aligned}$$

这里的 $\lceil \cdot \rceil$ 是上取整符号。GQA提供了MHA到MQA的自然过渡，当 $g = h$ 时就是MHA， $g = 1$ 时就是MQA，当 $1 < g < h$ 时，它只将KV Cache压缩到 $g/h$ ，压缩率不如MQA，但同时也提供了更大的自由度，效果上更有保证。GQA最知名的使用者，大概是Meta开源的LLAMA2-70B，以及LLAMA3全

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

更换为一般的线性变换：

$$\mathbf{o}_t^{(s)} = \text{Attention} \left( \mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)} \right) \triangleq \frac{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right)} \quad (5)$$

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_q^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{k}_i^{(s)} &= \mathbf{c}_i \mathbf{W}_k^{(s)} \in \mathbb{R}^{d_k}, & \mathbf{W}_k^{(s)} &\in \mathbb{R}^{d_c \times d_k} \\ \mathbf{v}_i^{(s)} &= \mathbf{c}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d_c \times d_v} \end{aligned}$$

$$\mathbf{c}_i = \mathbf{x}_i \mathbf{W}_c \in \mathbb{R}^{d_c}, \quad \mathbf{W}_c \in \mathbb{R}^{d \times d_c}$$

对此，MLA发现，我们可以结合Dot-Attention的具体形式，通过一个简单但不失巧妙的恒等变换来规避这个问题。首先，在训练阶段还是照常进行，此时优化空间不大；然后，在推理阶段，我们利用

矩阵吸收：

$$\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} = \left( \mathbf{x}_t \mathbf{W}_q^{(s)} \right) \left( \mathbf{c}_i \mathbf{W}_k^{(s)} \right)^\top = \mathbf{x}_t \left( \mathbf{W}_q^{(s)} \mathbf{W}_k^{(s)\top} \right) \mathbf{c}_i^\top \quad (6)$$

这意味着推理阶段，我们可以将 $\mathbf{W}_q^{(s)} \mathbf{W}_k^{(s)\top}$ 合并起来作为Q的投影矩阵，那么 $\mathbf{c}_i$ 则取代了原本的 $\mathbf{k}_i$ ，同理，在 $\mathbf{o}_t$ 后面我们还有一个投影矩阵，于是 $\mathbf{v}_i^{(s)} = \mathbf{c}_i \mathbf{W}_v^{(s)}$ 的 $\mathbf{W}_v^{(s)}$ 也可以吸收到后面的投影矩阵中去，于是等效地 $\mathbf{v}_i$ 也可以用 $\mathbf{c}_i$ 代替，也就是说此时KV Cache只需要存下所有的 $\mathbf{c}_i$ 就行，而不至于存下所有的 $\mathbf{k}_i^{(s)}$ 、 $\mathbf{v}_i^{(s)}$ 。注意到 $\mathbf{c}_i$ 跟 $s$ 无关，也就是说是所有头共享的，即MLA在推理阶段它可以恒等变换为一个MQA。

刚才我们说了，MLA之所以能保持跟GQA一样大小的KV Cache，其关键一步是“将 $\mathbf{W}_q^{(s)} \mathbf{W}_k^{(s)\top}$ 合并成一个（跟位置无关的）矩阵作为Q的投影矩阵”，但如果加了RoPE的话，这一步就无法实现了。这是因为RoPE是一个跟位置相关的、 $d_k \times d_k$ 的分块对角矩阵 $\mathbf{R}_m$ ，满足 $\mathbf{R}_m \mathbf{R}_n^\top = \mathbf{R}_{m-n}$ ，MLA加入RoPE之后会让 $\mathbf{W}_q^{(s)} \mathbf{W}_k^{(s)\top}$ 之间多插入了一项 $\mathbf{R}_{t-i}$ ：

MLA 无法天然支持 RoPE：

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \mathbf{R}_i, & \mathbf{k}_i^{(s)} &= \mathbf{c}_i \mathbf{W}_k^{(s)} \mathbf{R}_i \\ \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} &= \left( \mathbf{x}_t \mathbf{W}_q^{(s)} \mathbf{R}_t \right) \left( \mathbf{c}_i \mathbf{W}_k^{(s)} \mathbf{R}_i \right)^\top = \mathbf{x}_t \left( \mathbf{W}_q^{(s)} \mathbf{R}_{t-i} \mathbf{W}_k^{(s)\top} \right) \mathbf{c}_i^\top \end{aligned} \quad (7)$$

这里的 $\mathbf{W}_q^{(s)} \mathbf{R}_{t-i} \mathbf{W}_k^{(s)\top}$ 就无法合并为一个固定的投影矩阵了（跟位置差 $t-i$ 相关），从而MLA的想法无法结合RoPE实现。

最后发布的MLA，采取了一种混合的方法——每个Attention Head的Q、K新增 $d_r$ 个维度用来添加RoPE，其中K新增的维度每个Head共享：

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

$$\mathbf{o}_t^{(s)} = \text{Attention} \left( \mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)} \right) \triangleq \frac{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp \left( \mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top} \right)}$$

解耦的 RoPE：

$$\begin{aligned} \mathbf{q}_i^{(s)} &= [\mathbf{x}_i \mathbf{W}_{qc}^{(s)}, \mathbf{x}_i \mathbf{W}_{qr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_k + d_r}, & \mathbf{W}_{qc}^{(s)} &\in \mathbb{R}^{d \times d_k}, \mathbf{W}_{qr}^{(s)} \in \mathbb{R}^{d \times d_r} \\ \mathbf{k}_i^{(s)} &= [\mathbf{c}_i \mathbf{W}_{kc}^{(s)}, \mathbf{c}_i \mathbf{W}_{kr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_k + d_r}, & \mathbf{W}_{kc}^{(s)} &\in \mathbb{R}^{d_c \times d_k}, \mathbf{W}_{kr}^{(s)} \in \mathbb{R}^{d_c \times d_r} \\ \mathbf{v}_i^{(s)} &= \mathbf{c}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d_c \times d_v} \\ \mathbf{c}_i &= \mathbf{x}_i \mathbf{W}_c \in \mathbb{R}^{d_c}, & \mathbf{W}_c &\in \mathbb{R}^{d \times d_c} \end{aligned} \quad (9)$$

这样一来，没有RoPE的维度就可以重复“Part 1”的操作，在推理时KV Cache只需要存 $\mathbf{c}_i$ ，新增的带RoPE的维度就可以用来补充位置信息，并且由于所有Head共享，所以也就只有在K Cache这里增加了 $d_r$ 个维度，原论文取了 $d_r = d_k/2 = 64$ ，相比原本的 $d_c = 512$ ，增加的幅度不大。

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

$$\mathbf{o}_t^{(s)} = \text{Attention}(\mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)}) \triangleq \frac{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top}) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top})}$$

训练阶段的 MLA:

$$\begin{aligned} \mathbf{q}_i^{(s)} &= [\mathbf{c}'_i \mathbf{W}_{qc}^{(s)}, \mathbf{c}'_i \mathbf{W}_{qr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_k + d_r}, & \mathbf{W}_{qc}^{(s)} &\in \mathbb{R}^{d'_c \times d_k}, \mathbf{W}_{qr}^{(s)} \in \mathbb{R}^{d'_c \times d_r} \\ \mathbf{k}_i^{(s)} &= [\mathbf{c}_i \mathbf{W}_{kc}^{(s)}, \mathbf{x}_i \mathbf{W}_{kr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_k + d_r}, & \mathbf{W}_{kc}^{(s)} &\in \mathbb{R}^{d_c \times d_k}, \mathbf{W}_{kr}^{(s)} \in \mathbb{R}^{d_c \times d_r} \\ \mathbf{v}_i^{(s)} &= \mathbf{c}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d_c \times d_v} \\ \mathbf{c}'_i &= \mathbf{x}_i \mathbf{W}'_c \in \mathbb{R}^{d'_c}, & \mathbf{W}'_c &\in \mathbb{R}^{d \times d'_c} \\ \mathbf{c}_i &= \mathbf{x}_i \mathbf{W}_c \in \mathbb{R}^{d_c}, & \mathbf{W}_c &\in \mathbb{R}^{d \times d_c} \end{aligned} \quad (10)$$

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)} \mathbf{W}_v^{(1)}, \mathbf{o}_t^{(2)} \mathbf{W}_v^{(2)}, \dots, \mathbf{o}_t^{(h)} \mathbf{W}_v^{(h)}]$$

$$\mathbf{o}_t^{(s)} = \text{Attention}(\mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{c}_{\leq t}) \triangleq \frac{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top}) \mathbf{c}_i}{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top})}$$

推理阶段的 MLA:

$$\begin{aligned} \mathbf{q}_i^{(s)} &= [\mathbf{c}'_i \mathbf{W}_{qc}^{(s)} \mathbf{W}_{kc}^{(s)\top}, \mathbf{c}'_i \mathbf{W}_{qr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_c + d_r} \\ \mathbf{k}_i^{(s)} &= [\mathbf{c}_i, \mathbf{x}_i \mathbf{W}_{kr}^{(s)} \mathbf{R}_i] \in \mathbb{R}^{d_c + d_r} \\ \mathbf{W}_{qc}^{(s)} &\in \mathbb{R}^{d'_c \times d_k}, \mathbf{W}_{kc}^{(s)} \in \mathbb{R}^{d_c \times d_k}, \mathbf{W}_{qr}^{(s)} \in \mathbb{R}^{d'_c \times d_r}, \mathbf{W}_{kr}^{(s)} \in \mathbb{R}^{d_c \times d_r} \\ \mathbf{c}'_i &= \mathbf{x}_i \mathbf{W}'_c \in \mathbb{R}^{d'_c}, & \mathbf{W}'_c &\in \mathbb{R}^{d \times d'_c} \\ \mathbf{c}_i &= \mathbf{x}_i \mathbf{W}_c \in \mathbb{R}^{d_c}, & \mathbf{W}_c &\in \mathbb{R}^{d \times d_c} \end{aligned} \quad (12)$$

$$\mathbf{o}_t = [\mathbf{o}_t^{(1)}, \mathbf{o}_t^{(2)}, \dots, \mathbf{o}_t^{(h)}]$$

$$\mathbf{o}_t^{(s)} = \text{Attention}(\mathbf{q}_t^{(s)}, \mathbf{k}_{\leq t}^{(s)}, \mathbf{v}_{\leq t}^{(s)}) \triangleq \frac{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top}) \mathbf{v}_i^{(s)}}{\sum_{i \leq t} \exp(\mathbf{q}_t^{(s)} \mathbf{k}_i^{(s)\top})} \quad (11)$$

带 RoPE 的 MHA:

$$\begin{aligned} \mathbf{q}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_q^{(s)} \mathbf{R}_i \in \mathbb{R}^{d_k}, & \mathbf{W}_q^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{k}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_k^{(s)} \mathbf{R}_i \in \mathbb{R}^{d_k}, & \mathbf{W}_k^{(s)} &\in \mathbb{R}^{d \times d_k} \\ \mathbf{v}_i^{(s)} &= \mathbf{x}_i \mathbf{W}_v^{(s)} \in \mathbb{R}^{d_v}, & \mathbf{W}_v^{(s)} &\in \mathbb{R}^{d \times d_v} \end{aligned}$$

可以发现，其实在训练阶段，除了多了一步低秩投影以及只在部分维度加RoPE外，MLA与Q、K的Head Size由 $d_k$ 换成 $d_k + d_r$ 的MHA基本无异。